Как компьютер читает текст

Кодирование и векторизация текста: от символов к векторам

Д.т.н., проф. каф. математики Владова Алла Юрьевна

Текст в цифры

Вид	Цель	Обратимо?	Примеры
Кодирование (encoding)	Хранение и передача	✅ Да, без потерь	ASCII, UTF-8, Unicode
Шифрование (encryption)	Скрыть содержимое от посторонних	✅ Да, с ключом	AES, RSA, Caesar
Сжатие (compression)	Уменьшить размер	✅ Да (lossless) / ⚠️ приблизительно (lossy)	gzip, Huffman, Brotli
Хеширование (hashing)	«Отпечаток» для проверки целостности	❌ Нет, одностороннее	SHA-256, MD5, bcrypt
Контрольная сумма (checksum)	Обнаружение ошибок при передаче	❌ Нет, фиксированный маленький выход	CRC32
Векторизация (vectorization)	Представление для ML-алгоритмов	⚠️ Приблизительно, иногда теряется смысл/порядок	One-hot, BoW, TF-IDF, Word2Vec, BERT
Стеганография (steganography)	Скрыть сам факт существования сообщения	✅ Да, с ключом	LSB в картинках, текст в аудио, в пробелах

План лекции

1

Символы → числа

Как буквы превращаются в коды: ASCII, Unicode, UTF-8

2

Язык данных

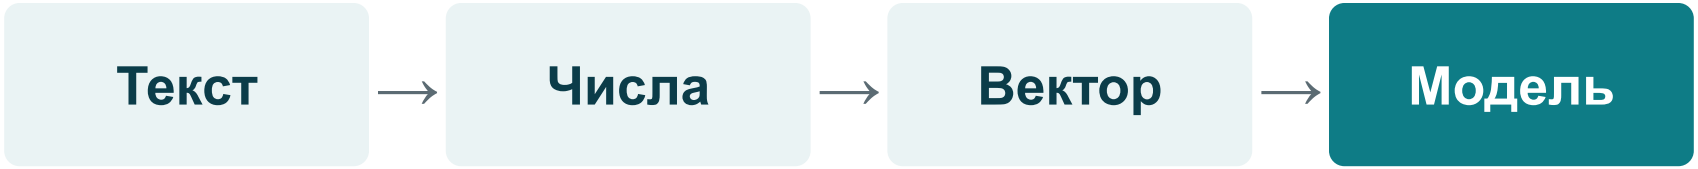
Токен, словарь, вектор — слова, которые нужны везде

3

Слова → векторы

One-hot — первый способ записать слово числами

Зачем превращать текст в числа



Где это нужно

Поиск

находит страницы по смыслу запроса

Спам-фильтр

отличает спам от обычных писем

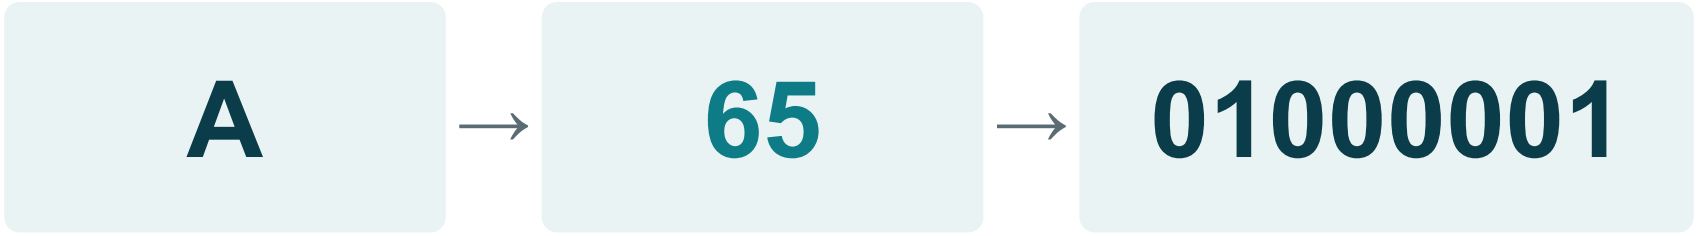
Чат-боты

понимают вопрос и находят ответ

Рекомендации

подбирают похожие товары и видео

У компьютера нет букв, только числа



Кодировка — это таблица: каждому символу соответствует число.

Если все пользуются одной таблицей, тексты можно передавать между компьютерами.

Первые коды: Морзе и Бодо

Азбука Морзе, 1838

E	•
T	—
A	• —
SOS	• • • — — — • • •

Только точки и тире. Частые буквы короче: «E» — одна точка.

Код Бодо, 1870

5 бит

= 32 разных комбинации

Хватило на латиницу и цифры. Для кириллицы нужно больше 50 символов — места не хватает.

По русской таблице Морзе расшифруйте фразу, где пробел /

-.- --- - / . ... - / .- .

-.-- -... ..-

Буква	Код Морзе	Буква	Код Морзе
А	•–	Р	•–•
Б	–•••	С	•••
В	•—	Т	–
Г	—•	У	••–
Д	–••	Ф	••–•
Е	•	Х	••••
Ж	•••–	Ц	–•–•
З	—••	Ч	——•
И	••	Ш	———
Й	•——	Щ	—•–
К	–•–	Ъ	•—•–•
Л	•–••	Ы	–•—
М	—	Ь	–••–
Н	–•	Э	•••–•••
О	———	Ю	••—
П	•—•	Я	•–•–

К -.-	О ---	Т -
пробел /	Е .	С ...
Т -	пробел /	Р .-.
Ы -.--	Б -...	У ..-

Вопрос

почему код Морзе для буквы «E» — это одна точка, а для «Q» — это **--.-**

ASCII: первый общий стандарт

128

символов в таблице (7 бит), 1963 год

Латиница, цифры, знаки и управляющие коды.

Русских букв в ASCII нет.

Что	Коды
Цифры 0–9	48–57
Заглавные A–Z	65–90
Строчные a–z	97–122
Управляющие	0–31

Например: A = 65, a = 97

Как использовать ASCII-код для английской «A»

- Зажмите и удерживайте клавишу **Alt на клавиатуре в Windows**
- На цифровой клавиатуре справа наберите число **65**.
- Отпустите клавишу Alt, и на экране появится буква **A**.

Cmd - powershell

```
C:\Users\Mi>powershell
Windows PowerShell
Copyright (C) Microsoft Corporation. All rights reserved.

PS C:\Users\Mi> [char]32

PS C:\Users\Mi> [char]65
A
PS C:\Users\Mi>
```

Переведите в текст. *ASCII код пробела 32 (DEC)

- 67 65 84 83 32
- 69 65 84 32
- 70 73 83 72 32

Буква	Dec	Hex	Bin	Буква	Dec	Hex	Bin
A	65	41	01000001	N	78	4E	01001110
B	66	42	01000010	O	79	4F	01001111
C	67	43	01000011	P	80	50	01010000
D	68	44	01000100	Q	81	51	01010001
E	69	45	01000101	R	82	52	01010010
F	70	46	01000110	S	83	53	01010011
G	71	47	01000111	T	84	54	01010100
H	72	48	01001000	U	85	55	01010101
I	73	49	01001001	V	86	56	01010110
J	74	4A	01001010	W	87	57	01010111
K	75	4B	01001011	X	88	58	01011000
L	76	4C	01001100	Y	89	59	01011001
M	77	4D	01001101	Z	90	5A	01011010

Каждый регион — своя кодировка ASCII

В 1980-е добавили 8-й бит: ещё 128 мест. Каждая страна заполнила их по-своему.

Байт E0 в кодировке	Буква
Windows-1251	**а**
KOI8-R	**Ю**
ISO-8859-5	**р**

Слово «Привет» в чужой кодировке:

оПХБЕР

Windows-1251 прочитали как KOI8-R

Ïðèâåò

Windows-1251 прочитали как Latin-1

Unicode: один номер на символ

Символ	Номер (code point)
А (кириллица)	U+0410
A (латиница)	U+0041
я	U+044F
китайский иероглиф	U+4E2D
смайлик	U+1F600

≈ 150 000

символов

150+

письменностей мира

Unicode — это таблица номеров. Как записать номер в байтах, решает UTF-8.

UTF-8: как хранить номера

Латиница (A)		**1 байт**
Кириллица (Я)		**2 байта**
Китайский иероглиф		**3 байта**
Смайлик		**4 байта**

Почему победил UTF-8

Латиница занимает 1 байт, как в ASCII: старые файлы читаются без изменений.

Около 98% сайтов используют UTF-8.

Слово «Привет» в UTF-8

П	р	и	в	е	т
U+041F	U+0440	U+0438	U+0432	U+0435	U+0442
D0 9F	**D1 80**	**D0 B8**	**D0 B2**	**D0 B5**	**D1 82**
2 байта	2 байта	2 байта	2 байта	2 байта	2 байта

6 символов × 2 байта = 12 байт

```
len("Привет".encode("utf-8"))   # 12
```

Итог: от Морзе до Unicode

1838	1870	1963	1980-е	1991
Морзе	**Бодо**	**ASCII**	**Кодовые страницы**	**Unicode**
точки и тире	5 бит, 32 символа	7 бит, только английский	8 бит, у каждого региона своя	один номер для каждого символа

Каждый новый стандарт решал проблему предыдущего.

Проверка Unicode кода

- Нажмите клавиши **Win + R**, введите charmap и нажмите **Enter**.
- Откроется окно со всеми доступными шрифтами и символами.
- Найдите нужную букву (например, заглавную **A**), кликните по ней, нажмите кнопку **«Выбрать»**, а затем **«Копировать»**.
- Вставьте символ в нужное место с помощью **Ctrl + V**.
  В правом нижнем углу этого окна таблица подскажет Unicod-код выбранного символа.

Через powershell

```
A
PS C:\Users\Mi> [char]0x04E
N
PS C:\Users\Mi> [char]0x41
A
```

Запишите текст для Unicode

Cats and dogs

Вывод

- Мы научились превращать символы в байты. Но как превращать слова в векторы для ML? Об этом — One-hot, Bag of Words, TF-IDF.

Строительные блоки текста

Символ

одна буква, цифра или знак

Пример

«к» «5» «!»

Токен

кусочек текста, с которым работает алгоритм (чаще всего слово)

Пример

«кот»

Документ

один отдельный текст: твит, письмо, статья

Пример

«Кот спит на диване.»

Корпус

большая коллекция документов

Пример

все статьи Википедии

Словарь — все разные слова

Корпус из трёх текстов:

кот сидит	кот спит	пёс лает

Словарь — каждое слово один раз, у каждого свой номер:

кот	пёс	сидит	спит	лает
номер 0	номер 1	номер 2	номер 3	номер 4

Размер словаря |V| = 5 — столько чисел будет в one-hot векторе.

В реальных моделях: BERT — около 30 000 токенов, GPT-4 — около 100 000.

Число, вектор, матрица, тензор



Число

одно число



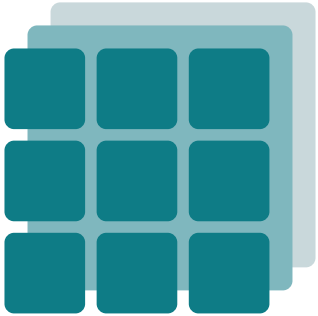
Вектор

один ряд чисел



Матрица

таблица: строки и столбцы



Тензор

стопка таблиц, измерений может быть сколько угодно

One-hot: слово как вектор

Словарь

кот — 0

пёс — 1

птица — 2

Правило

Единица стоит на месте номера слова, на остальных местах — нули.

кот	1	0	0
пёс	0	1	0
птица	0	0	1

One-hot на Python

```
vocab = ["кот", "пёс", "птица"]

def one_hot(word):
    vec = [0] * len(vocab)
    vec[vocab.index(word)] = 1
    return vec
```

Результат

one_hot("кот")

[1, 0, 0]

one_hot("пёс")

[0, 1, 0]

one_hot("птица")

[0, 0, 1]

Скалярное произведение векторов

$a = [a_1, a_2, ..., a_n]$ и **$b = [b_1, b_2, ..., b_n]$**

$a \cdot b = a_1 \times b_1 + a_2 \times b_2 + ... + a_n \times b_n$

Косинусное сходство векторов

$\cos(a, b) = (a \cdot b) / (|a| \times |b|)$

$|a| = \sqrt{(a_1^2 + a_2^2 + ... + a_n^2)}$ — длина вектора

Три проблемы one-hot

100 000

Слишком длинные

Словарь из 100 000 слов — вектор из 100 000 чисел, почти все нули.

0

Нет смысла

«кот» и «пёс» для модели так же далеки, как «кот» и «птица». Сходство всегда 0.

<UNK>

Новые слова

Слово не из словаря превращается в <UNK>, и модель его не понимает.

Два упрощённых способа

Label encoding

кот → 1, пёс → 2, птица → 3

Плюс: занимает мало памяти

Минус: придумывает порядок: получается, что «птица» больше «пса»

Hashing trick

слово → хеш → номер от 0 до K−1

Плюс: словарь хранить не нужно

Минус: разные слова могут получить один номер (коллизия)

Оба способа тоже не передают смысл слов.

Задание «Цветовая палитра» One-hot

Нужно определить настроение пользователя по введенному им цвету

1. Выберите словарь из 5 цветов
2. Запишите one-hot вектор для каждого цвета.
3. Сколько чисел в каждом векторе?
4. Сколько единиц и сколько нулей?
5. Чему равно скалярное произведение цвет1 x цвет2? Цвет1 x цвет1?

Палитра увеличилась

Если добавить ещё 95 цветов (всего 100):

- Какой длины станет каждый вектор?
- Какую долю вектора будут занимать нули?

Задание «Города и числа» label encoding

Вы кодируете города для модели предсказания цен на квартиры. Решили использовать label encoding — каждому городу присвоили целое число.

Найдите среднее арифметическое кодов городов.
Найдите расстояния **|город1 − город2|, |город2 − город3|**
Объясните физический смысл

Линейная регрессия

Цена = w × код_города + b.

Если обучить на этих данных, модель найдёт некоторый коэффициент **w**. Что физически означает этот **w**? Можно ли его интерпретировать?

Закодируйте те же 5 городов one-hot:

- Сколько чисел в каждом векторе?
- Сколько параметров потребуется линейной регрессии с one-hot? А с label encoding?
- В каком случае модель сможет дать отдельную цену для каждого города?

Эмбеддинг: вектор со смыслом

кот	[0.51, −0.32, 0.84, …]
собака	[0.49, −0.28, 0.81, …]
калькулятор	[−0.73, 0.45, −0.12, …]

Насколько слова близки (косинус)

кот и собака ≈ 0.92

кот и калькулятор ≈ 0.21

Чем ближе к 1, тем ближе слова по смыслу.

One-hot: длинный, одни нули, без смысла.

Эмбеддинг: короткий (например, 300 чисел), со смыслом.

Что запомнить

1. Компьютер работает с числами, поэтому текст нужно закодировать.
2. Unicode даёт номер каждому символу, UTF-8 записывает его в байты.
3. Токен, словарь, вектор — базовые понятия для всех методов.
4. One-hot — самый простой способ превратить слово в вектор, но без смысла.

Дальше: Bag of Words → TF-IDF → Word2Vec → BERT